

基于群体智能算法的无线传感器网络覆盖优化研究

李杜若, 王奕博, 韦世贸

课程名称: 群体智能 指导老师: 金博 汇报日期: 2026 年 6 月 18 日

摘要: 针对无线传感器网络节点部署中覆盖不足、覆盖冗余和通信连通性难以同时兼顾的问题, 本文基于项目代码建立网格化监测区域与二元感知模型, 设计覆盖率、冗余率和连通性加权的综合适应度函数, 并采用粒子群优化、灰狼优化、鲸鱼优化及其改进版本搜索传感器节点位置。在 Hard、Medium、Irregular 三类场景下, full 实验以 15 次独立运行统计均值和标准差, 并与 Random、Grid 基准方法比较。结果表明, PSO 在三个场景中的平均覆盖率分别为 0.4647、0.8878 和 0.9268, 相对随机部署均有明显提升; Grid 在规则区域中仍是强基准, 改进策略也未在所有场景稳定超过原算法, 说明参数设置和场景约束会显著影响群体智能算法效果。

关键词: 无线传感器网络; 覆盖优化; 群体智能; 粒子群优化; 灰狼优化

Coverage Optimization of Wireless Sensor Networks Based on Swarm Intelligence Algorithms

Abstract: This project studies coverage optimization in wireless sensor networks. A grid-based environment and a binary sensing model are built, and a weighted fitness function combines coverage, redundancy and connectivity. PSO, GWO, WOA and their improved variants are compared with random and grid baselines on Hard, Medium and Irregular scenarios. The full experiment uses 15 independent runs. Results show that PSO achieves the best overall swarm-intelligence performance, while the grid baseline remains strong in regular areas and the proposed improvement strategies are not uniformly superior.

Key words: wireless sensor networks; coverage optimization; swarm intelligence; PSO; GWO

无线传感器网络 (Wireless Sensor Network, WSN) 由大量具备感知、计算和通信能力的传感器节点构成, 可用于环境监测、智慧农业、灾害预警和物联网感知等场景。节点部署质量直接影响网络对目标区域的感知能力; 若节点分布过于随机, 容易出现覆盖空洞、局部重复覆盖以及节点间通信不足等问题。

规则网格部署具有简单、均匀和可解释的优势, 但它依赖人工规则, 对障碍物、不规则区域和动态部署任务的适应能力有限。群体智能算法能够把一组节点坐标视作一个候选解, 通过群体协作搜索高维连续空间, 因此适合用于 WSN 覆盖优化这类多目标、非线性问题。

本项目围绕课程要求完成了 WSN 环境建模、适应度函数设计、PSO/GWO/WOA 及改进版本实现、Random/Grid 基准对比、多场景 full 实验和可视化分析。图 1 给出了从环境建模到结果分析的整体流程。

WSN 覆盖优化实验流程




图 1 WSN 覆盖优化流程

1 WSN 覆盖优化模型

1.1 监测区域网格化

项目在 `wsn/environment.py` 中以 `WSNEnvironment` 表示二维监测区域。默认区域宽高均为 100，按照 `grid_resolution` 生成均匀网格点；若场景包含矩形或圆形障碍物，则先根据障碍物几何关系剔除无效网格点，覆盖率只在有效网格点上统计。传感器节点位置为二维坐标数组，既可以由 `random_deploy` 随机生成，也可以由 `grid_deploy` 按规则网格生成，还可以由群体智能算法直接设置。

1.2 二元感知模型

覆盖计算采用二元感知模型：对任一有效网格点，若它到至少一个传感器节点的欧氏距离不超过感知半径 R_s ，则认为该网格点被覆盖；否则为未覆盖。代码中 `coverage_matrix` 返回节点与网格点之间的布尔覆盖矩阵，`covered_grid_mask` 对每一列求逻辑或得到区域覆盖掩码。

1.3 连通性与冗余度

通信连通性由 `communication_adjacency` 计算：若两个节点距离不超过通信半径 R_c ，则认为二者可直接通信。`connectivity_rate` 进一步统计所有有向节点对中可通信节点对的比例。冗余度由 `FitnessEvaluator` 根据覆盖矩阵计算，含义是被覆盖网格点上除第一个覆盖节点之外的平均额外覆盖比例；冗余度越高，说明重复覆盖越多，可能带来资源浪费。

1.4 适应度函数设计

项目将覆盖率最大化、冗余度最小化和连通性提升合成为单一适应度函数，权重在 `FitnessEvaluator` 中归一化。本项目 full 实验采用默认权重 $w_1=0.5$ 、 $w_2=0.3$ 、 $w_3=0.2$ 。

$$F = 0.5 \times \text{Coverage} + 0.3 \times (1 - \text{Redundancy}) + 0.2 \times \text{Connectivity} \quad (1)$$

该函数使算法优先提高覆盖率，同时通过 $1 - \text{Redundancy}$ 抑制过度重复覆盖，并保留对通信连通性的约束。由于三个分量都被限制在 $[0,1]$ 附近，适应度数值便于在不同场景和不同算法之间横向比较。

2 群体智能算法设计

2.1 PSO 粒子群优化算法

粒子群优化（Particle Swarm Optimization, PSO）在项目中由 `wsn/algorithms/pso.py` 实现。每个粒子是一组节点坐标展平后的向量，维度为 $2 \times n_nodes$ 。粒子根据个体历史最优位置 `pbest` 和群体全局最优位置 `gbest` 更新速度与位置，位置更新后被裁剪在监测区域边界内，目标是最大化式（1）的适应度。

2.2 GWO 灰狼优化算法

灰狼优化（Grey Wolf Optimizer, GWO）把候选解视为狼群个体，通过 `alpha`、`beta`、`delta` 三个最优层级引导其他个体搜索。代码在每轮迭代中按适应度排序更新三类领导者，并依据距离向量和系数 `A`、`C` 生成新的位置。该机制兼顾全局探索和向优解靠拢。

2.3 WOA 鲸鱼优化算法

鲸鱼优化算法（Whale Optimization Algorithm，WOA）模拟座头鲸捕食行为，包括包围猎物、螺旋气泡网攻击和随机搜索三类更新方式。当参数 A 的模较小时，个体围绕当前最优解开发；当 A 较大时，个体参考随机个体进行探索，从而增加跳出局部最优的机会。

2.4 改进策略

项目在 wsn/improvements/ 下实现了三类改进策略。第一，Logistic 混沌初始化利用混沌序列替代均匀随机初始化，以提高初始种群多样性。第二，自适应参数使 PSO 惯性权重从 0.9 线性衰减到 0.4，使 GWO/WOA 的收敛因子非线性变化，用于平衡前期探索和后期开发。第三，高斯变异在迭代后半段对部分个体施加扰动，帮助跳出局部最优。需要注意的是，改进策略会增强探索，但也可能降低后期稳定收敛速度，因此不能预设其一定优于原算法。

3 实验设计

3.1 实验环境与参数设置

full 实验由 run_full_experiment.py 生成，并将结果保存为 results/full/full_results.json。正式报告以该 JSON 为主要依据，quick 与 lite 结果仅用于说明前期快速验证过程。表 1 汇总了 full 实验的主要配置。

表 1 full 实验总体参数设置

项目	取值
监测区域	100 × 100 二维区域
grid_res	2.0
max_iter	100
population	25
n_runs	15
通信半径 Rc	24.0
适应度权重	Coverage 0.5, 1-Redundancy 0.3, Connectivity 0.2

3.2 实验场景

实验设置 Hard、Medium、Irregular 三类场景。Hard 节点数较少且感知半径较小，用于考察稀疏部署下的搜索能力；Medium 增加节点数和感知半径，用于观察中等密度下算法性能；Irregular 在 Medium 参数基础上加入障碍物区域，用于模拟不规则可部署空间。场景参数见表 2。

表 2 full 实验场景设置

场景	节点数 n_nodes	感知半径 Rs	障碍物设置
Hard	25	8.0	无
Medium	40	10.0	无
Irregular	40	10.0	4 个障碍区域：2 个矩形、2 个圆形

3.3 对比方法与评价指标

对比方法包括 Random baseline、Grid baseline、PSO、ImprovedPSO、GWO、ImprovedGWO、WOA 和 ImprovedWOA。评价指标包括 Coverage、Fitness、Redundancy、Connectivity、Convergence iteration，以及 15 次独立运行得到的均值和标准差。标准差越小，说明算法在不同随机种子下越稳定。

4 实验结果与分析

4.1 覆盖率与适应度对比

表 3 至表 5 分别列出三个场景下各方法的 Fitness 和 Coverage 等指标。整体看，PSO 在三个场景中均取得最高的群体智能算法平均 Fitness，说明在当前参数规模下，PSO 的个体最优与全局最优协同机制更适合本项目的连续节点坐标优化问题。

表 3 Hard 场景下各算法 Fitness 和 Coverage 对比

Method	Fitness	Coverage	Convergence Iteration
Random	0.5111 ± 0.0105	0.3700 ± 0.0218	-
Grid	0.5622	0.4710	-
PSO	0.5672 ± 0.0042	0.4647 ± 0.0109	13.2000 ± 10.1535
ImprovedPSO	0.5594 ± 0.0044	0.4601 ± 0.0078	35.9333 ± 12.9227
GWO	0.5537 ± 0.0063	0.4266 ± 0.0209	29.2667 ± 21.5390
ImprovedGWO	0.5429 ± 0.0083	0.3916 ± 0.0324	14.2667 ± 19.5157
WOA	0.5574 ± 0.0056	0.4432 ± 0.0135	1.9333 ± 2.7439
ImprovedWOA	0.5481 ± 0.0083	0.4310 ± 0.0158	10.2000 ± 8.6116




图 2 Hard 场景覆盖率对比

表 4 Medium 场景下各算法 Fitness 和 Coverage 对比

Method	Fitness	Coverage	Convergence Iteration
Random	0.6601 ± 0.0163	0.6718 ± 0.0341	-
Grid	0.7952	0.9312	-
PSO	0.7672 ± 0.0057	0.8878 ± 0.0114	39.2667 ± 7.3889
ImprovedPSO	0.7460 ± 0.0083	0.8493 ± 0.0162	56.6667 ± 7.6216
GWO	0.7192 ± 0.0146	0.7769 ± 0.0397	54.2000 ± 36.6719
ImprovedGWO	0.6920 ± 0.0120	0.7144 ± 0.0336	7.3333 ± 21.6169
WOA	0.7498 ± 0.0057	0.8488 ± 0.0114	18.5333 ± 9.0027
ImprovedWOA	0.7329 ± 0.0122	0.8166 ± 0.0263	22.3333 ± 10.0907




图 3 Medium 场景覆盖率对比

表 5 Irregular 场景下各算法 Fitness 和 Coverage 对比

Method	Fitness	Coverage	Convergence Iteration
Random	0.6768 $\pm$ 0.0172	0.7063 $\pm$ 0.0358	-
Grid	0.8094	0.9606	-
PSO	0.7862 $\pm$ 0.0079	0.9268 $\pm$ 0.0146	37.0000 $\pm$ 9.3808
ImprovedPSO	0.7650 $\pm$ 0.0110	0.8879 $\pm$ 0.0210	56.0000 $\pm$ 8.7483
GWO	0.7338 $\pm$ 0.0180	0.8032 $\pm$ 0.0443	62.0000 $\pm$ 34.1858
ImprovedGWO	0.7071 $\pm$ 0.0139	0.7424 $\pm$ 0.0358	19.9333 $\pm$ 34.9752
WOA	0.7581 $\pm$ 0.0102	0.8665 $\pm$ 0.0214	17.8667 $\pm$ 12.6589
ImprovedWOA	0.7432 $\pm$ 0.0121	0.8385 $\pm$ 0.0236	27.8000 $\pm$ 13.2675




图 4 Irregular 场景覆盖率对比

与 Random baseline 相比，PSO 在 Hard、Medium、Irregular 三个场景的覆盖率提升分别为 9.47、21.60 和 22.05 个百分点，说明群体智能搜索能显著改善随机部署带来的覆盖空洞问题。表 6 汇总了这一提升幅度。

表 6 PSO 相比 Random baseline 的覆盖率提升幅度

场景	Random 平均覆盖率	PSO 平均覆盖率	提升幅度
Hard	0.3700	0.4647	9.47 个百分点
Medium	0.6718	0.8878	21.60 个百分点
Irregular	0.7063	0.9268	22.05 个百分点

4.2 与 Grid baseline 的比较

Grid baseline 在 Medium 和 Irregular 场景下覆盖率分别达到 0.9312 和 0.9606，均高于 PSO 的 0.8878 和 0.9268。这一结果不应回避：在当前参数下，规则网格在近似均匀、连通的可部署区域内具有天然的均匀覆盖优势，因此是很强的基准。群体智能算法的价值主要在于不依赖人工排布规则，能够扩展到障碍物、更复杂约束、动态节点、能耗约束和真实地理区域等场景。

4.3 改进算法效果分析

full 结果显示，ImprovedPSO、ImprovedGWO、ImprovedWOA 并未在所有场景稳定超过对应原算法。例如 ImprovedPSO 在三个场景中的平均覆盖率均低于 PSO。可能原因包括：改进参数尚未充分调优；混沌初始化和变异增强探索，但会推迟后期收敛；当前问题规模和 100 次迭代下，原始 PSO 已能较快找到较优解；改进策略的收益依赖场景复杂度和参数组合。参数敏感性实验表明，mutation_rate 与 mutation_scale 会影响 ImprovedPSO 表现，表 7 给出了当前 full 数据中表现较好的五组组合，说明该策略更适合作为后续细调对象，而不是直接宣称优于原算法。

表 7 ImprovedPSO 参数敏感性 Top 5 组合

排序	mutation_rate	mutation_scale	Mean Fitness	Std Fitness
1	0.05	0.05	0.7611	0.0054
2	0.05	0.10	0.7580	0.0016
3	0.10	0.05	0.7568	0.0019
4	0.05	0.02	0.7566	0.0018
5	0.20	0.02	0.7565	0.0024

4.4 稳定性与收敛性分析

从标准差看，PSO 在三个场景的 Fitness 标准差分别为 0.0042、0.0057 和 0.0079，整体波动较小；GWO 与 ImprovedGWO 在 Medium、Irregular 场景中标准差更大，说明其受随机种子和领导者层级变化影响更明显。图 5 给出了 PSO、GWO、WOA 在三类场景下达到 95% 最终适应度所需的平均迭代次数。WOA 在 Hard 和 Medium 中收敛较快，但最终 Fitness 不如 PSO；PSO 的收敛速度不是最快，却获得了更好的最终综合指标。




图 5 算法收敛迭代次数对比

图 6 从分布角度展示了 PSO、ImprovedPSO 和 WOA 的 15 次运行 Fitness。箱体越窄表示稳定性越好，中位线越高表示典型运行效果越好。可以看到 PSO 在三个场景中均保持较高的中位水平，支持其作为本实验综合表现最佳算法的结论。




图 6 多次运行结果箱线图

4.5 可视化分析

图 7 展示了 Irregular 场景下 PSO 最优种子的节点部署和覆盖热力图。灰色区域为障碍物，不参与覆盖统计；红色点为传感器节点。热力图中颜色越深代表被更多节点覆盖。该图说明算法能够在有效区域内形成较均匀的覆盖分布，但局部仍存在多节点重复覆盖，后续可通过更强的冗余惩罚或多目标优化进一步改善。




图 7 覆盖热力图

5 项目分工与实现说明

本项目由小组协作完成。李杜若主要负责 WSN 覆盖模型搭建，包括监测区域网格化、二元感知模型、覆盖率、冗余率和连通性适应度函数设计；王奕博主要负责群体智能算法实现，包括 PSO、GWO、WOA 及改进策略的核心优化逻辑；韦世贸主要负责可视化和对比实验，包括覆盖率热力图、收敛曲线、箱线图和实验结果分析。实际开发过程中，三部分工作相互依赖，模型接口、算法输出和可视化数据格式需要不断联调，因此项目以模块化方式推进。

6 结论与展望

本项目围绕 WSN 覆盖优化问题，完成了建模、算法实现、实验对比和可视化分析。项目建立了网格化监测区域和二元感知模型，设计了覆盖率、冗余率、连通性的综合评价函数，实现了 PSO、GWO、WOA 及其改进版本，并通过 full 实验进行了 15 次独立运行统计。结果表明，PSO 在三个场景中取得最好的群体智能算法综合表现，相对随机部署显著提升覆盖率；Grid 在近似均匀、连通的可部署区域中仍是强基准，说明算法比较需要结合场景结构进行解释；改进策略未全面优于原算法，后续应继续调参与开展消融实验。

后续工作可以从五个方向扩展：一是加入移动距离或能耗模型，使节点调整成本进入优化目标；二是引入真实地理区域和更复杂障碍物；三是考虑动态节点失效和在线重部署；四是采用 NSGA-II 或多目标 PSO 直接处理覆盖率、冗余度、连通性之间的权衡；五是增加实际部署成本约束，使模型更贴近工程应用。

参考文献

- [1] Kennedy J, Eberhart R. Particle swarm optimization[C]//Proceedings of ICNN'95 - International Conference on Neural Networks. Perth: IEEE, 1995: 1942-1948.
- [2] Mirjalili S, Mirjalili S M, Lewis A. Grey Wolf Optimizer[J]. Advances in Engineering Software, 2014, 69: 46-61.

- [3] Mirjalili S, Lewis A. The Whale Optimization Algorithm[J]. Advances in Engineering Software, 2016, 95: 51-67.
- [4] Yick J, Mukherjee B, Ghosal D. Wireless sensor network survey[J]. Computer Networks, 2008, 52(12): 2292-2330.
- [5] Wang X, Wang S, Ma J. An improved co-evolutionary particle swarm optimization for wireless sensor networks with dynamic deployment[J]. Sensors, 2007, 7(3): 354-370.
- [6] 项目源代码与实验结果文件.